

# Устранение экспоненциальной сложности оценки стоимости бермудского опциона

Анастасия Миллер

СПбГУ, 6<sup>ой</sup> семестр, 322 гр.  
26 мая 2014 г.

## 1 Вступление

В книге [4] был предложен метод оценки американских опционов с конечным множеством дат погашения. Две оценки – смещённая вверх и смещённая вниз – получаются с помощью смоделированного дерева, которое вевтится при каждой возможности раннего погашения опциона. Оценки являются состоятельными (т.е. сходятся по вероятности к истинной цене опциона) и асимптотически несмещёнными.

Один из основных недостатков алгоритма – его экспоненциальная сложность. Здесь же предлагается несколько подходов, которые заменят экспоненциальную сложность полиномиальной с одновременным увеличением «случайности» алгоритма.

## 2 Общая идея алгоритма

Начиная с некоторого момента  $t_k$ , когда общее число состояний достигнет некоторого  $n$ , мы перестанем генерировать дочерние вершины ко всем состояниям. В следующий момент времени,  $t_{k+1}$ , мы будем иметь всё так же  $n$  состояний, а не  $bn$ . Этого можно достичь, если генерировать дочерние состояния не ко всем вершинам, а только к некоторым. К каким?

## 2.1 Анализ распределения состояний с помощью гистограммы

В том случае, когда состояние актива  $S$  является числом в  $\mathbb{R}^1$ , в качестве параметра  $X$ , распределение которого нас интересует, можно использовать само  $S$ , иначе можно использовать  $h(S)$ .

Деля интервал  $[\min_{i \in 1:n} X_i; \max_{i \in 1:n} X_i + \frac{1}{n})$  на  $k$  равных частей  $[a_{k-1}, a_k)$ , где  $a_0 = \min_{i \in 1:n} X_i$ ,  $a_k = \max_{i \in 1:n} X_i$ , мы можем определить частоты  $f_k = \#\{X_i | X_i \in [a_{k-1}, a_k)\} / n$  попадания событий в различные части отрезка. Из состояний, сгруппированных на отрезке  $[a_{k-1}, a_k)$ , мы также можем создать некоторый «средний арифметический» вектор, координаты которого будут являться средним арифметическим координат всех состояний, оказавшихся на данном отрезке, и уже для этого нового среднего состояния – представителя отрезка – генерировать дочерние вершины в количестве  $n \cdot f_k$ . Для всех состояний, оказавшихся в этом отрезке, дочерними вершинами будут являться все вершины, полученные от их представителя.

Таким образом, количество рассматриваемых состояний не увеличится. С другой стороны, этот метод предполагает хранение в памяти всего дерева, а не только непосредственно обчитываемой ветки, как это предполагалось в исходной работе [3].

## 2.2 Кластеризация состояний

Для выделения родителей будущего поколения событий можно использовать не гистограммный подход, а кластеризацию существующего поколения. Так как состояния являются векторами в  $\mathbb{R}^d$ , в качестве метрики можно взять, например, «улучшенную» евклидову метрику в  $\mathbb{R}^d$ :

$$\mu(S_i, S_j) = \sqrt{\sum_{k=1}^d \frac{(s_k^i - s_k^j)^2}{c_k}},$$

где  $c_k = |\max_{i \in 1:n} s_k^i - \min_{i \in 1:n} s_k^i|$ , т.е. масштабирующий множитель, уравновешивающий влияние различных компонент состояний на итоговое расстояние между ними.

Кластеризация может быть проведена по любому из известных алгоритмов, разберём один из наиболее простых и популярных алгоритмов кластеризации применительно к нашей задаче – алгоритм  $k$ -средних.

```

// назначаем центрами кластеров случайно выбранные  $S_k$ 
for  $j \in 1 : k$  do
    |  $\text{Get}(\alpha)$ 
    |  $C_j = S_{\lceil n\alpha \rceil}, \forall i \in 1 : j-1, C_i \neq C_j$ 
end
for  $j \in 1 : n$  do
    | // центроидом для каждого состояния полагаем тот из
    |   центроидов, который ближе всего к данному состоянию
    |  $S_j.\text{centroid} = \text{argmin}(i \in 1 : k, \mu(S_j, C_i))$ 
end
changed = true
repeat
    | for  $j \in 1 : k$  do
    |   | centroid =  $\{i \in 1 : n | S_i.\text{centroid} = C_j\}$ 
    |   |  $C_j = \frac{1}{\#(\text{centroid})} \sum_{i \in \text{centroid}} S_i$ 
    |   end
    | changed = false
    | for  $j \in 1 : n$  do
    |   | // пересчитываем принадлежность состояний центроидам
    |   | oldcentroid =  $S_j.\text{centroid}$ 
    |   |  $S_j.\text{centroid} = \text{argmin}(i \in 1 : k, \mu(S_j, C_i))$ 
    |   | changed = (oldcentroid  $\neq$   $S_j.\text{centroid}$ )
    |   end
until changed = false

```

В этом случае набор центроидов  $\{C_j\}_{j=1}^k$ , можно использовать в качестве родителей для следующего поколения состояний.

Известные недостатки алгоритма  $k$ -средних, такие как сложность  $O(2^n)$  в худшем случае, зависимость результатов от начального выбора центроидов (которая, впрочем, может быть частично устранена при модификации алгоритма, например, в версии  $k$ -means++, описанной в [1])

### 3 Выбор $k$

Выбор количества родителей для будущего поколения – отдельный вопрос. Скорее всего, количество родителей будет непосредственно влиять на величину доверительного интервала результата.

### Список литературы

- [1] David Arthur и Sergei Vassilvitskii. “k-means++: The Advantages of Careful Seeding”. В: *SODA*. 2007. URL: <http://theory.stanford.edu/~sergei/papers/kMeansPP-soda.pdf>.
- [2] Mark Broadie, Paul Glasserman и Gautam Jain. “Enhanced Monte Carlo estimates for american option prices”. В: *Journal of Derivatives* 5.1 (Fall) (1997), с. 25–44.
- [3] М. Broadie и Р. Glasserman. “Pricing American-style securities by simulation”. Английский. В: *Journal of Economic Dynamics and Control* 21 (1997), с. 1323–1352.
- [4] Paul Glasserman. *Monte Carlo Methods in Financial Engineering*. Английский. Springer, 2004.